

Cadenas de Markov

Lo que ocurra mañana dependerá de lo sucedido hoy...



Bibliografía Sugerida:

Investigación de Operaciones. Hamdy Taha.

Cadenas de Markov. Teoría y Aplicaciones. H. Rojo y M. Miranda. Apunte I3CT4

Procesos estocásticos - Introducción

Un **Proceso Estocástico** estudia el comportamiento en el tiempo de una sistema dinámico que posee naturaleza aleatoria.

“La presencia de un fenómeno aleatorio hace que el sistema evolucione según el parámetro, que normalmente es el tiempo t , cambiando probabilísticamente de estado.”

Entonces, “al realizar una serie de observaciones del proceso en diferentes momentos y bajo las mismas condiciones, los resultados de las observaciones serán, generalmente, diferentes.”

En otras palabras, un proceso o sucesión de eventos que se desarrolla en el tiempo en el cual el resultado en cualquier etapa contiene algún elemento que depende del “azar” se denomina **proceso aleatorio** o **proceso estocástico**.

Procesos estocásticos - Introducción

“Para describir el comportamiento del sistema es necesario definir una **variable aleatoria $X(t)$** que represente una característica mensurable de los distintos estados que puede adoptar el sistema según sea el resultado del fenómeno aleatorio y su correspondiente **probabilidad de estado asociada $P[X(t)]$** .”

$$\text{P.E.} \quad \left\{ T \ ; \ X(t)_{t \in T} \ ; \ P[X(t)] \right\}$$

Tiempo	Comportamiento de la variable aleatoria en el tiempo	Probabilidad de la variable aleatoria
--------	---	---

Un ejemplo podría ser las condiciones del tiempo en Buenos Aires en una serie de días consecutivos: el tiempo cambia día a día de una manera que en apariencia es algo aleatoria. O bien, la sucesión podría consistir en los precios de las acciones que cotizan en la bolsa en donde otra vez interviene cierto grado de aleatoriedad.


Procesos estocásticos - Ejemplos

Otros ejemplos de procesos estocásticos podrían ser:

- ▶ El número de vehículos esperando en un peaje en el instante t .
- ▶ El número total de llamadas recibidas solicitando un determinado servicio hasta el instante t .
- ▶ El número de máquinas descompuestas o en reparación en un determinado taller en el instante t .
- ▶ El nivel de inventario de cierto producto al final del día t .
- ▶ El valor de una determinada acción en el instante t .

Procesos estocásticos - Ejemplos

Por ejemplo, la evolución del número de compradores en un local comercial al ser abierto al público, entre las 8:00 y 9:40 de la mañana (100 minutos) puede ser representada por un proceso estocástico y una posible realización de éste se observa en la siguiente gráfica:



Procesos estocásticos - Introducción

Un ejemplo de un proceso estocástico es una sucesión de lanzamientos de una moneda. En este caso, el resultado en cualquier etapa es independiente de todos los resultados previos (esta condición de independencia es parte de la definición de los ensayos de Bernoulli).

Sin embargo, en la mayoría de los procesos estocásticos, cada resultado depende de lo que sucedió en etapas anteriores del proceso. Por ejemplo, el tiempo en un día determinado no es totalmente aleatorio sino que es afectado en cierto grado por el tiempo de días previos. El precio de una acción al cierre de cualquier día depende en cierta medida del comportamiento de la bolsa en días previos.

Procesos estocásticos - Clasificación

- ▶ Según la memoria que guarda el proceso de la historia de los estados anteriores:
 - ▶ **Procesos aleatorios puros:** la probabilidad de que el sistema se encuentre en un estado cualquiera $X(t)$ en un instante t se puede calcular de manera independiente a cuales fueron los estados anteriores.
 - ▶ Ejemplos: Ensayos independientes al azar: dados, ruleta, etc.
 - ▶ **Procesos sin memoria (markovianos):** la probabilidad de que el sistema se encuentre en un estado cualquiera $X(t)$ en un instante t se puede calcular conociendo el estado inmediato anterior.
 - ▶ Ejemplos: Sistema de filas de espera, niveles de inventarios, campañas de marketing, etc.
 - ▶ **Procesos con memoria.**

Procesos estocásticos markovianos

En la mayoría de los procesos estocásticos, cada resultado depende de lo que sucedió en etapas anteriores del proceso. Por ejemplo, el tiempo en un día determinado no es totalmente aleatorio sino que es afectado en cierto grado por el tiempo de días previos. El precio de una acción al cierre de cualquier día depende en cierta medida del comportamiento de la bolsa en días previos.

Un caso simple de un proceso estocástico en que los resultados dependen de otros, ocurre cuando el resultado en cada etapa sólo depende del resultado de la etapa anterior y no de cualquiera de los resultados previos. Tal proceso se denomina **proceso de Markov.**

Estos procesos tienen memoria, recuerdan el último evento y eso condiciona las posibilidades de los eventos futuros. Esto justamente los distingue de una serie de eventos independientes como el hecho de tirar una moneda.

Procesos de Markov - Clasificación

- ▶ Según la naturaleza discreta o continua del espacio de estados de la variable $X(t)$:
 - ▶ **Proceso de Markov**: cuando $X(t)$ representa una magnitud continua (energía, potencia, corriente eléctrica, etc.) estamos en presencia de un **Proceso de Markov con estados continuos** o simplemente **Proceso de Markov**.
 - ▶ **Cadena de Markov**: cuando $X(t)$ representa una magnitud discreta (unidades en stock en un depósito, cantidad de clientes en un sistema de filas de espera, etc.) estamos en presencia de un **Proceso de Markov con estados discretos** o simplemente **Cadena de Markov**.

Procesos de Markov - Clasificación


- ▶ Según la naturaleza discreta o continua del parámetro tiempo t :
 - ▶ **Parámetro continuo**: la definición de la variable aleatoria $X(t)$ requiere la especificación del parámetro t , es decir, del conjunto de instantes en que se puede observar los estados del sistema. Así si las observaciones se realizan en cualquier instante del continuo ($t \geq 0$), hablamos de un **proceso o cadena de Markov de parámetro continuo**.
 - ▶ **Parámetro discreto**: cuando las observaciones se efectúan en determinados instantes de tiempo (por ejemplo, a cada hora $t = 0, 1, 2, \dots$), hablamos de un **proceso o cadena de Markov de parámetro discreto**.

Procesos de Markov - Clasificación

- Clasificación de los procesos de Markov según la naturaleza discreta o continua del espacio de estados de la variable $X(t)$ y del parámetro tiempo t :

		Naturaleza del espacio de estados $X(t)$	
		Discreto	Continuo
Naturaleza del parámetro tiempo t	Discreto ($t = 0, 1, 2, \dots$)	Cadenas de Markov de parámetro discreto	Procesos de Markov de parámetro discreto
	Continuo ($t \geq 0$)	Cadenas de Markov de parámetro continuo	Procesos de Markov de parámetro continuo

Procesos Estocásticos, Procesos de Markov y Cadenas de Markov



Repasando

Una *Cadena de Markov* es una serie de eventos (de una variable aleatoria de magnitud discreta), donde la probabilidad de que ocurra un evento determinado depende del evento inmediato anterior.

Por lo tanto, el último evento condiciona las posibilidades de los eventos futuros, por lo que se dice que las cadenas de este tipo tienen *memoria*. "*Recuerdan*" el último evento.

En otras palabras, una cadena de Markov es una sucesión de ensayos similares u observaciones en los cuales cada ensayo tiene el mismo número finito de resultados posibles y en donde la probabilidad de cada resultado para un ensayo dado depende sólo del resultado del ensayo inmediatamente precedente y no de cualquier resultado previo.

Propiedad de Markov

Dada una secuencia de variables aleatorias $X_1, X_2, X_3, \dots$ tales que el valor de X_n es el estado del proceso en el tiempo n .

Si la distribución de probabilidad condicional de X_{n+1} en estados pasados es una función de X_n por sí sola, entonces:

$$\boxed{P(X_{n+1} = x_{n+1} / X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_2 = x_2, X_1 = x_1) = P(X_{n+1} = x_{n+1} / X_n = x_n)}$$

Donde x_i es el estado del proceso en el instante i .

Esto implica que el estado en $t+1$ sólo depende del estado en t y no de la evolución anterior del sistema.

Matriz de Transición

Al trabajar con cadenas de Markov, es útil pensar la sucesión de ensayos como experimentos efectuados en cierto sistema físico, cada resultado dejando a este sistema en cierto estado.

Por ejemplo, consideremos una sucesión de elecciones políticas en cierto país: el sistema podría tomarse como el país mismo y cada elección lo dejaría en cierto estado, es decir en el control del partido ganador.

Si sólo hay dos partidos políticos fuertes que se alternan en el gobierno, llamados A y B, entonces podemos decir que el país se encuentra en el estado A o B si el partido A o B ganara la elección. Cada ensayo (o sea cada elección), coloca al país en uno de los dos estados A o B.

Matriz de Transición

Una sucesión de 10 elecciones podría producir resultados tales como los siguientes:

A, B, A, A, B, B, B, A, B, B

La primera elección en la sucesión deja en el poder al partido A, la segunda fue ganada por el partido B, y así sucesivamente, hasta que la décima elección la gane el partido B.

Supongamos que las probabilidades de que el partido A o B ganen la próxima elección son determinadas por completo por el partido que está en el poder ahora.

Matriz de Transición


Por ejemplo podríamos tener las probabilidades siguientes:

- Si el partido A está en el poder, existe una probabilidad de $\frac{1}{4}$ que el partido A ganará la próxima elección y una probabilidad de $\frac{3}{4}$ de que el partido B gane la elección siguiente.
- Si el partido B está en el poder, hay una probabilidad de $\frac{1}{3}$ de que el partido A gane la elección siguiente y una probabilidad de $\frac{2}{3}$ que el partido B permanezca en el poder.

Matriz de Transición

En tal caso, la sucesión de elecciones forman una cadena de Markov, dado que las probabilidades de los dos resultados de cada elección están determinadas por el resultado de la elección precedente.

Lo descrito anteriormente puede representarse gráficamente usando la siguiente red:



Los círculos A y B se denominan nodos y representan los estados del proceso, las flechas que van de un nodo a si mismo o al otro son los arcos y representan la probabilidad de cambiar de un estado al otro

Matriz de Transición

La información probabilística que se acaba de dar se puede representar de manera conveniente por la siguiente matriz:

Resultado de la próxima elección		A	B
Resultado de la última elección	A	$1/4$	$3/4$
	B	$1/3$	$2/3$

Esta matriz se denomina **matriz de transición**. Los elementos de la matriz de transición representan las probabilidades de que en el próximo ensayo el estado del sistema del partido indicado a la izquierda de la matriz cambie al estado del partido indicado arriba de la matriz.

Matriz de Transición

Definición: Consideremos un proceso de Markov en que el sistema posee n estados posibles, dados por los números $1, 2, 3, \dots, n$. Denotemos p_{ij} a la probabilidad de que el sistema pase al estado j después de cualquier ensayo en donde su estado previo era i . Los números p_{ij} se denominan probabilidades de transición y la matriz $n \times n$ $P = (p_{ij})$ se conoce como **matriz de transición del sistema**.

Además se cumple que:

- ▶ $p_{i1} + p_{i2} + \dots + p_{in} = 1$
- ▶ Cada $p_{ij} \geq 0$

Vector de estado inicial

Consideremos un sistema de n estados posibles. Para cualquier etapa en el futuro (m transiciones) no podemos predecir en qué estado se encontrará el sistema pero sí podríamos definir las probabilidades de que se encuentre en cada uno de los estados $1, 2, \dots, n$.

En general, si $p_1, p_2, \dots, p_n$ son las probabilidades de que el sistema se encuentre en los estados $1, 2, \dots, n$, respectivamente, entonces la matriz de dimensión $1 \times n$ $(p_1, p_2, \dots, p_n)$ se conoce como matriz de estado inicial o **vector de estado inicial** del sistema. Obviamente que la suma de esa fila es 1. Denotaremos a la matriz de estado inicial como $P^{(0)}$ y a la matriz de estado después de k ensayos o etapas por $P^{(k)}$.

Vector de estado inicial

Tomemos otro ejemplo. Consideremos el valor de una acción que varía a diario. Cuando la bolsa de valores se encuentra estable, un incremento en un día tiende a anteceder una baja el día siguiente, y una baja por lo regular es seguida por un alza. Por lo tanto, las probabilidades de alza y baja del valor del acción se pueden representar a través de la siguiente matriz de transición:

$$\begin{array}{cc} & \begin{array}{cc} \text{A} & \text{B} \end{array} \\ \begin{array}{c} \text{A} \\ \text{B} \end{array} & \begin{pmatrix} 0,1 & 0,9 \\ 0,8 & 0,2 \end{pmatrix} \end{array}$$

Vector de estado inicial

Si ayer se obtuvo una baja en el valor de la acción, el vector de estado inicial resultante sería:

$$P^{(0)} = (0 \quad 1)$$

En la matriz de transición vemos que después de un día, la acción está en alza con probabilidad de 0,8 y en baja con probabilidad de 0,2, así, la matriz de estado P_1 después de un día está dada por:

$$P^{(1)} = (0,8 \quad 0,2)$$

Vector de estado inicial

La probabilidad de que la acción vaya al alza o a la baja después de dos días sería:

$$p_1 = (0,8)(0,1) + (0,2)(0,8) = 0,24$$

$$p_2 = (0,8)(0,9) + (0,2)(0,2) = 0,76$$

Por lo tanto, el vector de estado luego de dos días resulta:

$$P^{(2)} = (0,24 \quad 0,76)$$

De esta forma podemos obtener el vector de estado en cualquier etapa conociendo el vector de estado del ensayo previo.

Probabilidad de Transición de m pasos

Una de las propiedades de la matriz de transición es que es estacionaria. Es decir, no cambia con el tiempo. Esto también implica:

Definición: Consideremos un proceso de Markov en que el sistema posee n estados posibles, dados por los números $1, 2, 3, \dots, n$. Denotemos $p_{ij}^{(m)}$ a la probabilidad de que el sistema pase al estado j luego de m ensayos en donde su estado previo era i . Se denomina $p_{ij}^{(m)}$ a las **probabilidades de transición de m pasos**.

Matriz de transición de m pasos

Definición: Si P denota la matriz de transición de una cadena de Markov y $P^{(n)}$ es la matriz de estado después de n ensayos, entonces la matriz de estado $P^{(n+1)}$ después del ensayo siguiente está dada por:

$$P^{(n+1)} = P^{(n)} \cdot P$$

Ecuaciones de Chapman-Kolmogorov

Las ecuaciones de Chapman-Kolmogorov proporcionan un método para calcular las probabilidades de transición de n pasos $p_{ij}^{(n)}$.

Al ir del estado i al estado j en n pasos el proceso estará en algún estado k después de exactamente m pasos, lo que se expresa de la siguiente manera:

$$P_{ij}^{(n)} = \sum_{k=0}^M P_{ik}^{(m)} P_{kj}^{(n-m)}$$

Representa la probabilidad condicional de que, si se comienza en el estado i el proceso vaya al estado k después de m pasos y después al estado j en $n-m$ pasos.

Ecuaciones de Chapman-Kolmogorov

Como ya vimos, esto mismo se puede expresar de otra forma:

$$P(n+m) = P(n) \cdot P(m)$$

Luego, si $m = n = 1$ tenemos:

$$P(2) = P(1) \cdot P(1)$$

Si $m = 1$ y $n = r - 1$ tenemos:

$$P(r - 1 + 1) = P(r - 1) \cdot P(1) = P(r)$$

Cadenas de Markov

Veamos un ejemplo

El problema del Jardinero

Cadenas de Markov – Segunda clase

RETOMANDO...

Procesos de Markov - Clasificación

- Clasificación de los procesos de Markov según la naturaleza discreta o continua del espacio de estados de la variable $X(t)$ y del parámetro tiempo t :

		Naturaleza del espacio de estados $X(t)$	
		Discreto	Continuo
Naturaleza del parámetro tiempo t	Discreto ($t = 0, 1, 2, \dots$)	Cadenas de Markov de parámetro discreto	Procesos de Markov de parámetro discreto
	Continuo ($t \geq 0$)	Cadenas de Markov de parámetro continua	Procesos de Markov de parámetro continuo

Matriz de Transición

Definición: Consideremos un proceso de Markov en que el sistema posee n estados posibles, dados por los números $1, 2, 3, \dots, n$. Denotemos p_{ij} a la probabilidad de que el sistema pase al estado j después de cualquier ensayo en donde su estado previo era i . Los números p_{ij} se denominan probabilidades de transición y la matriz $n \times n$ $P = (p_{ij})$ se conoce como **matriz de transición del sistema**.

Además se cumple que:

- ▶ $p_{i1} + p_{i2} + \dots + p_{in} = 1$
- ▶ Cada $p_{ij} \geq 0$

Matriz de transición de m pasos

Definición: Si P denota la matriz de transición de una cadena de Markov y $P^{(n)}$ es la matriz de estado después de n ensayos, entonces la matriz de estado $P^{(n+1)}$ después del ensayo siguiente está dada por:

$$P^{(n+1)} = P^{(n)} \cdot P$$

Vector de estado inicial

En general, si $p_1, p_2, \dots, p_n$ son las probabilidades de que el sistema se encuentre en los estados $1, 2, \dots, n$, respectivamente, entonces la matriz de dimensión $1 \times n$ $(p_1, p_2, \dots, p_n)$ se conoce como matriz de estado inicial o **vector de estado inicial** del sistema. Obviamente que la suma de esa fila es 1. Denotaremos a la matriz de estado inicial como $P^{(0)}$ y a la matriz de estado después de k ensayos o etapas por $P^{(k)}$.

El **vector de estado inicial** del sistema estará conformado por ceros y un uno, identificando este el estado inicial en el que se encuentra el sistema.

Ejemplo:

$$P^{(0)} = (0 \quad 1)$$

Ecuaciones de Chapman-Kolmogorov

Las ecuaciones de Chapman-Kolmogorov proporcionan un método para calcular las probabilidades de transición de n pasos $p_{ij}^{(n)}$.

Al ir del estado i al estado j en n pasos el proceso estará en algún estado k después de exactamente m pasos, lo que se expresa de la siguiente manera:

$$P_{ij}^{(n)} = \sum_{k=0}^M P_{ik}^{(m)} P_{kj}^{(n-m)}$$

Representa la probabilidad condicional de que, si se comienza en el estado i el proceso vaya al estado k después de m pasos y después al estado j en $n-m$ pasos.

Cadenas de Markov Homogéneas

En una cadena de Markov, en la que $X(t)$ representa una magnitud discreta como cantidad de unidades en stock, clientes en una cola, etc., Δt representa el lapso de tiempo (discreto o continuo) en el que se produce una “transición”, es decir, el posible cambio de estado de $X(t)$

(a diferencia de un proceso de markov , en donde $X(t)$ representa por ejemplo, corriente eléctrica, presión, etc.).

Decimos entonces que una Cadena de Markov es homogénea cuando la probabilidad condicional de transición del estado i al estado j en cualquier instante t sólo depende de la diferencia Δt .

$$P \{ X(t + \Delta t) = j / X(t) = i \} = P_{ij} (t, t + \Delta t)$$

Clasificación de las Cadenas de Markov Homogéneas

Estados accesibles

Un estado j es accesible desde un estado i si se cumple que para algún paso $n \geq 1$ es $P_{ij}(n) > 0$, lo que significa que es posible pasar del estado i al estado j luego de un número de transiciones.

La accesibilidad es una propiedad transitiva:

Si $i \rightarrow j$ y $j \rightarrow k$, entonces $i \rightarrow k$

Clasificación de las Cadenas de Markov Homogéneas

Estados comunicantes

Dos estados i y j son comunicantes si j es accesible desde i y viceversa.

La comunicación también es una propiedad transitiva:

Si $i \leftrightarrow j$ y $j \leftrightarrow k$, entonces $i \leftrightarrow k$

Clasificación de las Cadenas de Markov Homogéneas

Clase comunicante

Una clase comunicantes es un conjunto de estados que se comunican todos entre sí. Como caso particular, la clase puede consistir en un solo estado.

Las clases comunicantes se pueden clasificar en **recurrentes** y **transitorias**.

Clasificación de las Cadenas de Markov Homogéneas

Clase comunicante - Clases recurrentes

Una clase es **recurrente** cuando la probabilidad de que la cadena se encuentre en un estado de dicha clase después de ∞ transiciones es positiva. Esto significa que una vez que alcanza dicha clase, siempre regresará a ella.

Un caso especial de una clases recurrentes lo constituyen los **estados absorbentes**, que son aquellos estados que una vez alcanzados no pueden ser abandonados.

Clasificación de las Cadenas de Markov Homogéneas

Clase comunicante - Clases transitorias

Una clase es **transitoria** cuando la probabilidad de que la cadena se encuentre en un estado de dicha clase después de ∞ transiciones es nula. Esto significa que una vez que alcanza dicha clase existe una probabilidad de que no retorne nunca a ella.

Clasificación de las Cadenas de Markov Homogéneas

Estados sin retorno


Son aquellos estados que no se comunican con ningún otro estado, ni si quiera consigo mismo. Esto significa que una vez que la cadena ha alcanzado dicho estado la probabilidad de que retorne a él es nula.

Clasificación de las Cadenas de Markov Homogéneas



Clasificación de las Cadenas de Markov Homogéneas

Veamos algunos ejemplos:



- ▶ El estado 4 es accesible desde los estados 2, 3 y 4 en un paso, desde el 1 en dos pasos y desde el estado 0 en tres pasos.
- ▶ Los estados 5 y 7 son comunicantes.
- ▶ Algunas clases comunicantes: $C1 = \{2\}$, $C2 = \{3, 4\}$, $C3 = \{5, 6, 7\}$
- ▶ $C3$ es una clase recurrente
- ▶ $C1$ y $C2$ son clases transitorias.
- ▶ Los estados 0 y 1 son estados sin retorno.

Clasificación de las Cadenas de Markov Homogéneas: **Ergódicas** y **no Ergódicas**

Una cadena de Markov homogénea es **ergódica** o irreducible cuando todos sus estados se comunican, es decir, constituyen una única clase comunicante recurrente.

Las cadenas ergódicas pueden ser clasificadas en **regulares** y **periódicas**.

Clasificación de las Cadenas de Markov Homogéneas: **Ergódicas** y **no Ergódicas**

Cadenas ergódicas regulares

Una cadena ergódica es regular o aperiódica cuando todos los estados pueden comunicarse simultáneamente en una cantidad r de pasos. En estas condiciones, P^r es una matriz con todos sus elementos no nulos.

Un criterio para comprobar que una cadena es regular consiste en calcular las sucesivas potencias de P hasta encontrar un número r de pasos tal que la matriz P^r tiene todos sus elementos no nulos.

Clasificación de las Cadenas de Markov Homogéneas: **Ergódicas** y **no Ergódicas**

Cadenas ergódicas periódicas

Una cadena ergódica es periódica cuando no se puede encontrar una potencia r de P para la cual todos los elementos de P^r sean no nulos. En estas condiciones las sucesivas potencias de la matriz P^r denotan un patrón periódico que permite asegurar siempre la presencia de al menos un cero en P^r .

Clasificación de las Cadenas de Markov Homogéneas: **Ergódicas** y **no Ergódicas**


Cadenas no ergódicas

Una cadena de Markov es no **ergódica** o reductible o separable cuando no todos sus estados se comunican, en esas condiciones la cadena es separable en un conjunto de clases comunicantes y estados sin retorno.

Volvamos a la cadena del ejemplo:


Clasificación de las Cadenas de Markov Homogéneas

Cadena no ergódica



- ▶ Clases comunicantes: $C_1 = \{2\}$, $C_2 = \{3, 4\}$, $C_3 = \{5, 6, 7\}$
- ▶ La cadena es separable en:
 - ▶ C_3 es una clase recurrente
 - ▶ C_1 y C_2 son clases transitorias.
 - ▶ Los estados 0 y 1 son estados sin retorno.

Clasificación de las Cadenas de Markov Homogéneas: Ergodicidad



Régimen Permanente y Régimen Transitorio

Se define como **Régimen Permanente** o **Estado Estacionario** de una cadena de Markov homogénea a la situación que el sistema alcanza luego de un período relativamente largo de tiempo.

En dicho régimen la cadena ya ha entrado en una condición de equilibrio estocástico, lo que significa que sus probabilidades de estado devienen estables en el tiempo.

Regimen transitorio es la situación en que el sistema se encuentra luego de un período relativamente corto a través del cual la cadena no ha encontrado una condición de equilibrio estocástico, por lo que sus probabilidades de estado no son estables en el tiempo.

Condiciones para alcanzar el Régimen Permanente o Estado Estacionario.

El estudio de las **Cadenas Ergódicas Regulares** interesa particularmente porque las conclusiones, bajo determinadas condiciones, son extensibles a las **Cadenas Ergódicas Periódicas** y a las **clases recurrentes de las cadenas no ergódicas**.

Como vamos a ver a continuación, sólo puede asegurarse que una cadena de Markov será estable en el régimen permanente o en otras palabras, admite estado estacionario, cuando es una cadena **Ergódica Regular**.

Comportamiento de la cadenas regulares en el régimen permanente

Para describir el comportamiento de una cadena regular en el régimen permanente o al largo plazo es preciso conocer las probabilidades de transición y de estado cuando el número n de transiciones a ∞ .

Se puede demostrar que si la cadena es **regular**, el límite de la matriz de de transición $P(n)$ cuando n tiende a ∞ es una matriz regular (todos sus elementos son positivos y todas sus filas iguales). Es decir:

$$\lim_{n \rightarrow \infty} P(n) = \lim_{n \rightarrow \infty} P^n \begin{vmatrix} P_0 & \dots & P_j & \dots & P_m \\ P_0 & \dots & P_j & \dots & P_m \\ P_0 & \dots & P_j & \dots & P_m \end{vmatrix}$$

Comportamiento de la cadenas regulares en el régimen permanente

Luego, aplicando la ecuación de Chapman - Kolmogorov obtenemos:

$$\lim_{n \rightarrow \infty} P(n) = P(0) \cdot \lim_{n \rightarrow \infty} P(n) = | P_0(0) \dots P_i(0) \dots P_m(0) | \times$$

$$\begin{vmatrix} P_0 & \dots & P_j & \dots & P_m \\ P_0 & \dots & P_j & \dots & P_m \\ P_0 & \dots & P_j & \dots & P_m \end{vmatrix}$$

Y por cumplirse que : $\sum_{i=0}^m P_i(0) = 1$, queda:

$$\lim_{n \rightarrow \infty} P(n) = P = | P_0 \dots P_i \dots P_m |$$

Comportamiento de la cadenas regulares en el régimen permanente

Estas ecuaciones expresan que una cadena de Markov regular , luego de un número suficientemente grande de transiciones ($n \rightarrow \infty$), sus probabilidades de transición y de estado se estabilizan en valores límites iguales para cada estado j , e independientes del estado inicial i .

Este estado es el que conocemos como el estado o régimen estacionario y sus probabilidades de estado representan los porcentajes de tiempo que la cadena permanece en cada estado luego de un período largo de tiempo.

Dicho de otra forma, representan las probabilidades de que el sistema se encuentre en un determinado estado en el largo plazo.

Cálculo del estado estacionario

El estado estacionario se puede calcular de tres maneras distintas:

1 – Mediante: $\lim P(n) = \lim P^n$, con $n \rightarrow \infty$

Es decir, elevando a la n a la matriz de transiciones P .

2 – Mediante :

Si $p(n) = p(n-1) \cdot P$

Y además $\lim_{n \rightarrow \infty} p(n) = \lim_{n \rightarrow \infty} p(n-1) = p$,

Reemplazando entonces tenemos que: $p = p \cdot P$

Y dado que :

$$\sum_{j=0}^m P_j(0) = I$$

Cálculo del estado estacionario

Luego, conocida la matriz de transición P de la cadena regular, se puede calcular el vector de probabilidades p del régimen permanente.

Entonces si: $p = p \cdot P$

Luego: $p \cdot \{P - I\} = 0$

La matriz $A = [P - I]$ define un sistema de ecuaciones linealmente dependientes. Para calcular las probabilidades de estado en régimen permanente se excluye una de las ecuaciones y se reemplaza por una ecuación (B) que indica que la sumatoria de probabilidades es igual a 1.

Cálculo del estado estacionario

El vector **p** se obtiene resolviendo:

$$\mathbf{p} = \mathbf{B} \cdot \mathbf{A}^{-1}$$

3 – Mediante la ecuación de flujos probabilísticos.

$$\sum_{i \neq j} P_i \cdot P_{ij} = P_j \cdot \sum_{j \neq k} P_{jk}$$

Esta es la ecuación de flujos probabilísticos, y expresa que para un nodo genérico **j** la suma de los flujos probabilísticos que concurren al nodo es igual a la suma de flujos probabilísticos que salen del nodo.
